Detecção de Fraudes

Comparação entre Regressão Logística e Isolation Forest, com análise com e sem PCA

1. Objetivo

Este relatório compara uma abordagem supervisionada, a Regressão Logística, com uma abordagem não supervisionada, o Isolation Forest, para detecção de fraudes em transações financeiras. A análise prioriza Recall e F1-Score, pois falsos negativos representam fraudes não detectadas.

2. Base de dados e desbalanceamento

A base contém 284.807 transações, das quais apenas 492 são fraudes. A classe positiva representa 0,1727% do total, o que torna a acurácia isolada uma métrica inadequada.

Classe	Quantidade	Proporção
Normal	284.315	99,8273%
Fraude	492	0,1727%

Um classificador ingênuo que previsse todas as transações como normais atingiria 99,8273% de acurácia, mas teria Recall igual a zero para fraude.

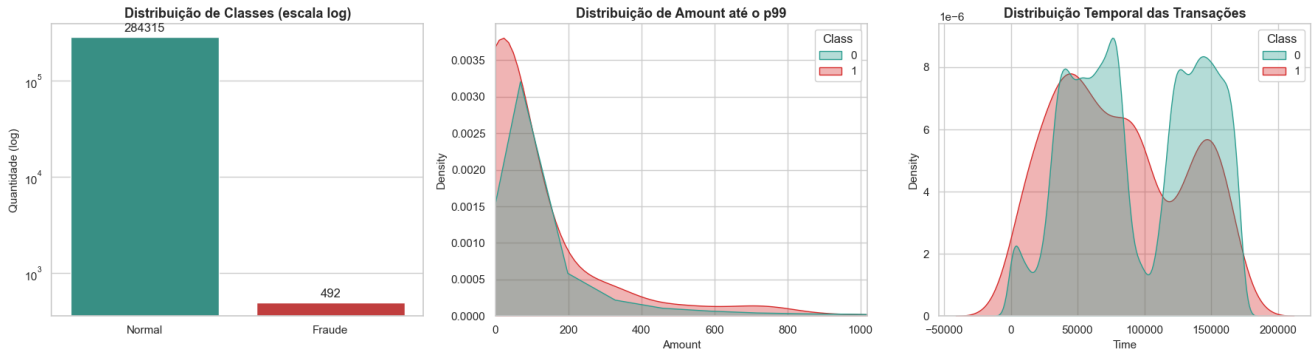

Figura 1. Distribuição das classes, comportamento de Amount e distribuição temporal das transações.

3. Metodologia

• Divisão treino/teste estratificada, preservando a proporção da classe fraude.

• Padronização com StandardScaler ajustado apenas no treino, evitando vazamento de informação.

• PCA ajustado exclusivamente no treino; 20 componentes explicaram 72,53% da variância.

• Seleção de hiperparâmetros em validação interna e avaliação final no conjunto de teste.

• Avaliação por matriz de confusão, Precision, Recall, F1, ROC-AUC e PR-AUC.

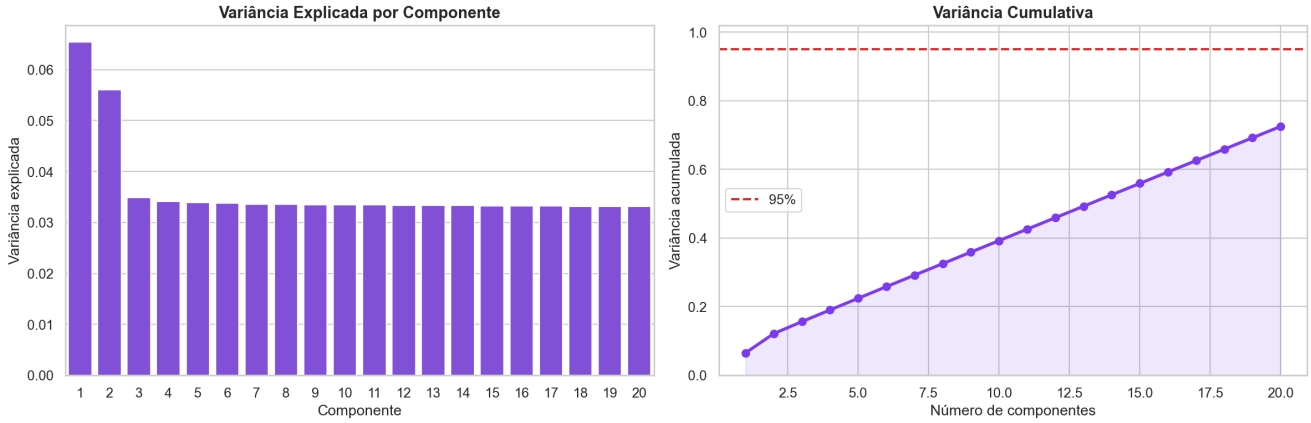

Figura 2. Variância explicada por componente e variância cumulativa no PCA com 20 componentes.

4. Hiperparâmetros avaliados

Regressão Logística

• Regularização: L1, L2 e ElasticNet.

• C: 0.01, 0.1, 1 e 10.

• class_weight: padrão e 'balanced'.

• Threshold ajustado em validação para maximizar F1-Score.

Isolation Forest

• Variações de n_estimators.

• Variações de contamination, incluindo a taxa real de fraude.

• Variações de max_samples.

• Conversão de predição: -1 como fraude e 1 como normal.

5. Resultados no teste

Modelo	Precision	Recall	F1	ROC-AUC	PR-AUC	FP	FN	TP
Reg. Logística - Sem PCA	0,8560	0,7230	0,7839	0,9669	0,6907	18	41	107
Isolation Forest - Sem PCA	0,3816	0,1959	0,2589	0,9424	0,1561	47	119	29
Reg. Logística - Com PCA	0,8201	0,7703	0,7944	0,9490	0,7053	25	34	114
Isolation Forest - Com PCA	0,1258	0,1284	0,1271	0,9360	0,0836	132	129	19

A Regressão Logística com PCA apresentou o melhor equilíbrio geral: F1 = 0,7944, Recall = 0,7703 e Precision = 0,8201. Ela detectou 114 das 148 fraudes no teste.

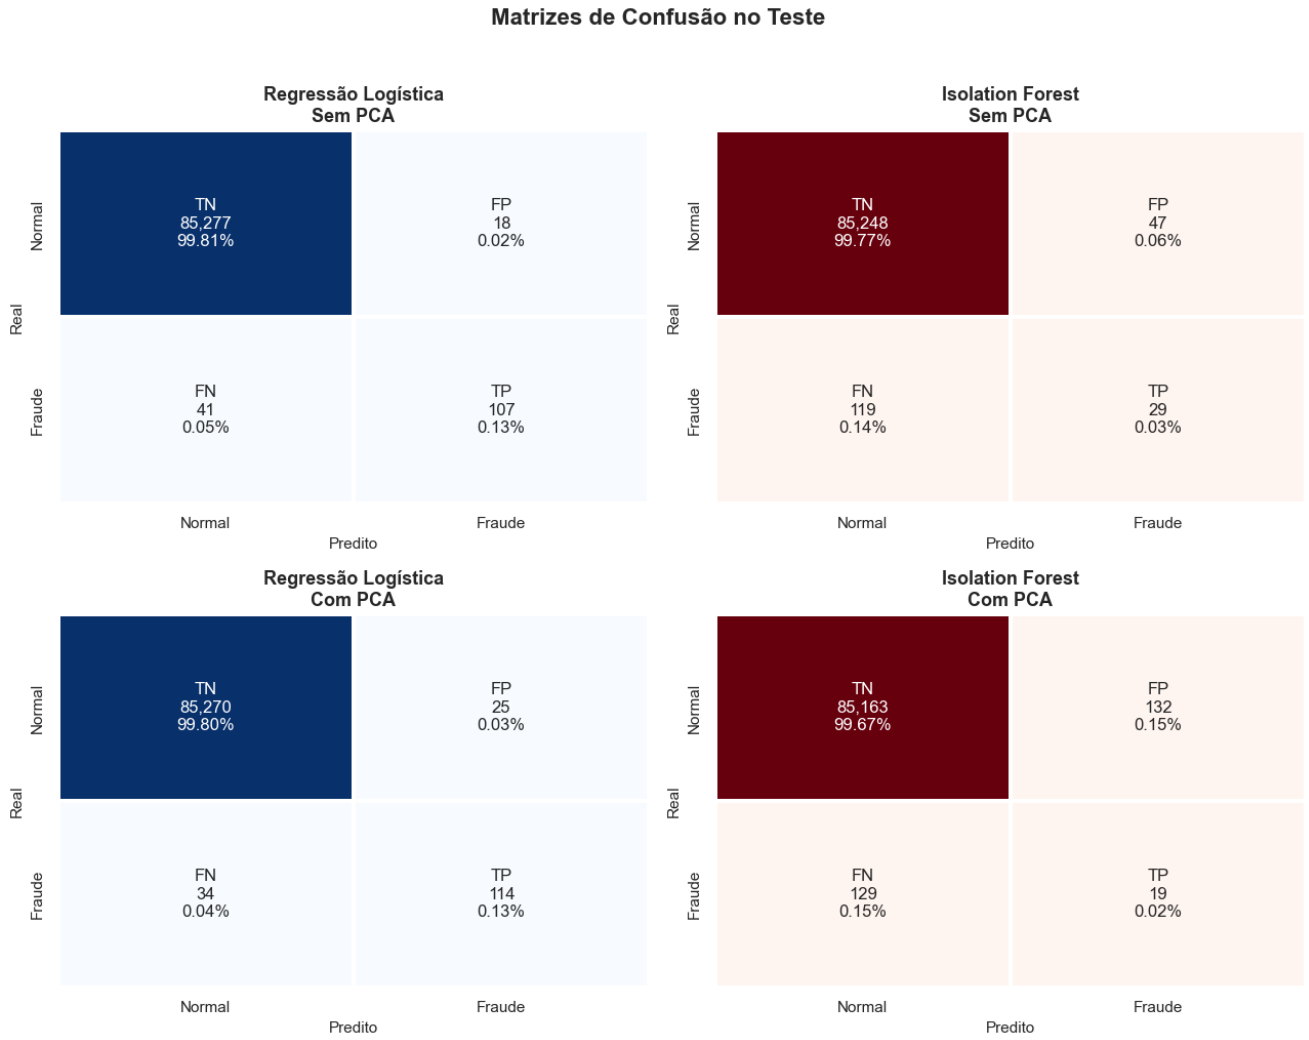

Figura 3. Matrizes de confusão dos quatro modelos finais no conjunto de teste.

6. Curvas Precision-Recall e comparação visual

A curva Precision-Recall é especialmente relevante em bases desbalanceadas, pois mostra a qualidade do modelo na classe minoritária. As curvas da Regressão Logística ficam muito acima da linha de base da taxa de fraude.

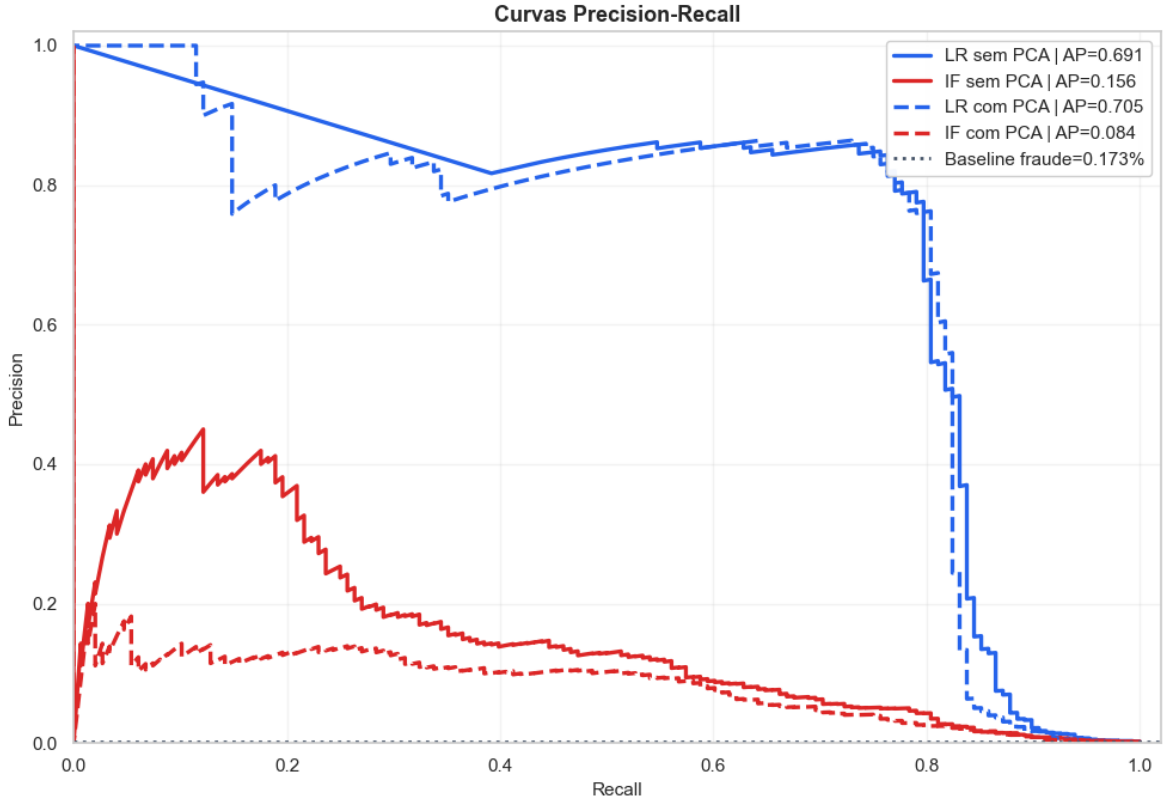

Figura 4. Curvas Precision-Recall dos modelos finais. AP representa Average Precision.

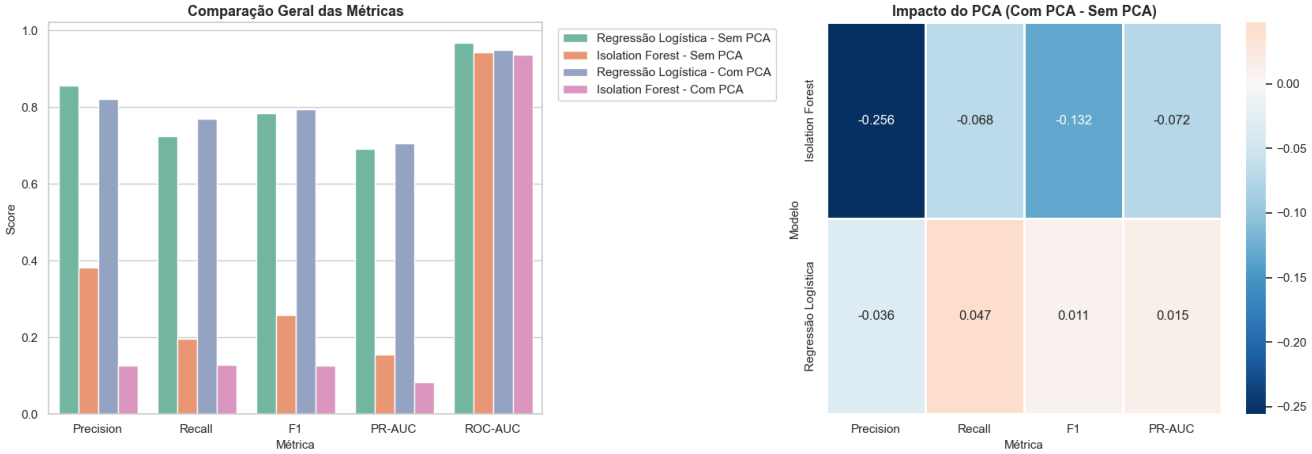

Figura 5. Comparação geral das métricas e impacto do PCA em cada modelo.

7. Falsos positivos, falsos negativos e PCA 2D

Em fraude, falsos negativos são mais críticos, pois representam fraudes aprovadas como transações normais. Falsos positivos geram atrito com clientes e custo de revisão, mas são mais recuperáveis.

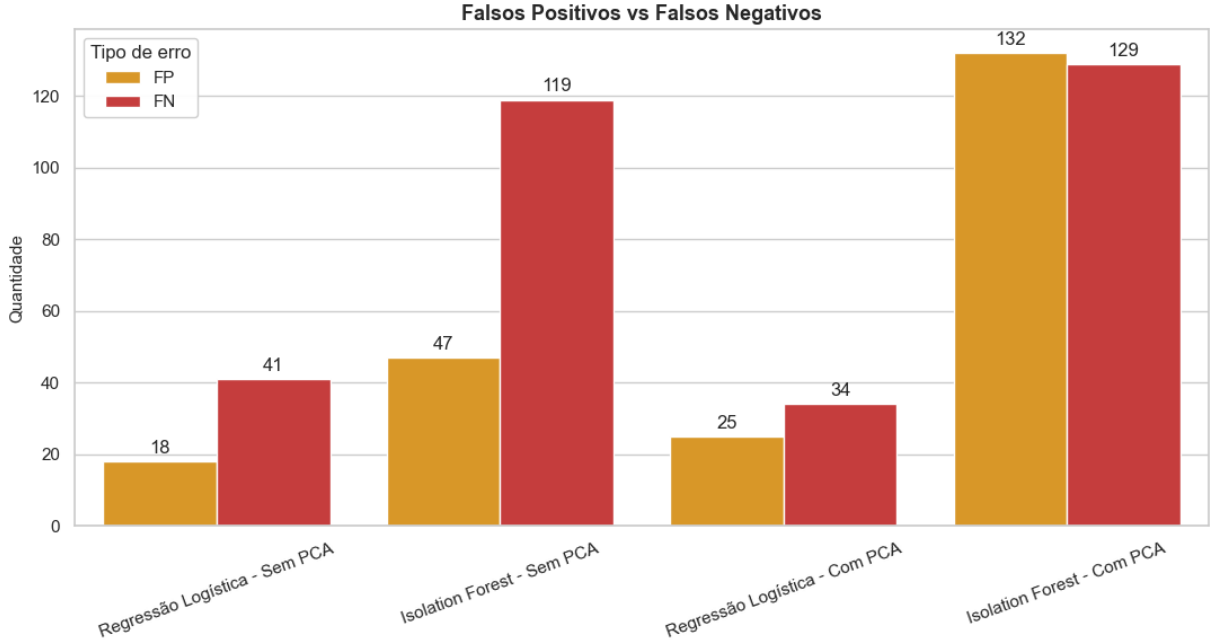

Figura 6. Comparação entre falsos positivos e falsos negativos por modelo.

A visualização em PCA 2D mostra que as fraudes não formam um bloco completamente separado das transações normais. Isso explica a dificuldade do problema e reforça a importância de métricas centradas na classe fraude.

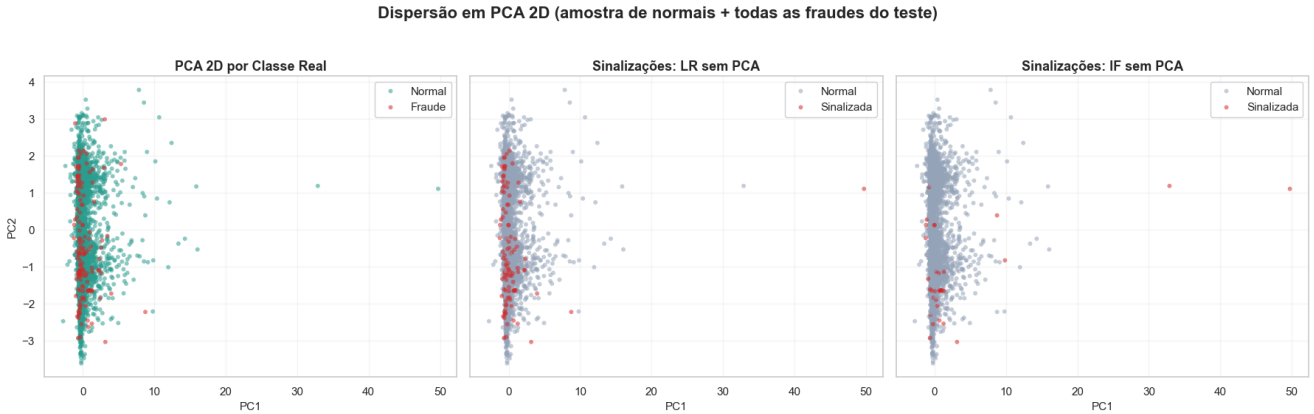

Figura 7. Dispersão em PCA 2D com classe real e sinalizações dos modelos.

8. Insights finais

Melhor equilíbrio por F1: Regressão Logística com PCA, com F1 = 0,7944, Recall = 0,7703 e Precision = 0,8201. O maior Recall também foi obtido pela Regressão Logística com PCA.

1) Por que o problema é desafiador e acurácia não basta?

Fraudes são raras; a classe positiva é muito pequena. Um modelo que prevê tudo como normal tem acurácia altíssima, mas Recall zero para fraude. Por isso, métricas como Recall, F1 e PR-AUC são mais informativas, pois avaliam diretamente a capacidade de encontrar a classe minoritária.

2) Impacto da regularização e do class_weight na Regressão Logística

A regularização L1 pode zerar coeficientes e simplificar o modelo; L2 tende a ser mais estável; ElasticNet combina seleção e estabilidade. O uso de class_weight='balanced' aumenta o peso da classe fraude no treinamento, geralmente elevando Recall, mas podendo reduzir Precision por aumentar falsos positivos. O threshold foi ajustado em validação para maximizar F1, evitando depender cegamente do corte 0,5.

3) Sensibilidade do Isolation Forest

O parâmetro contamination controla quantos pontos serão tratados como anomalia. Valores baixos reduzem falsos positivos, mas podem aumentar falsos negativos; valores altos aumentam Recall, mas tendem a derrubar Precision. Como o método não usa rótulos no ajuste, ele é útil quando os rótulos são escassos ou incertos, mas pode confundir comportamento raro legítimo com fraude.

4) PCA ajudou ou prejudicou?

Para a Regressão Logística, o PCA ajudou levemente: F1 = +0,0105, Recall = +0,0473 e PR-AUC = +0,0145. Para o Isolation Forest, o PCA prejudicou: F1 = -0,1318, Recall = -0,0676 e PR-AUC = -0,0724. O PCA deve ser interpretado como uma troca entre compressão/redução de ruído e possível perda de informação discriminativa.

5) Em que cenário usar cada abordagem?

Usaria Regressão Logística quando há histórico rotulado confiável, necessidade de interpretabilidade e calibragem operacional por threshold. Usaria Isolation Forest quando faltam rótulos, quando se deseja triagem inicial de anomalias ou monitoramento de padrões novos.

6) É possível combinar os dois métodos?

Sim. Pode-se usar votação OR para maximizar Recall, votação AND para maximizar Precision, uma cascata Isolation Forest -> Regressão Logística para triagem e refinamento, ou stacking usando os scores de ambos.

7) Conexão com outros domínios

A mesma lógica aparece em cibersegurança, manutenção preditiva, saúde, IoT e controle de qualidade: eventos críticos são raros, rótulos podem ser incompletos e o custo de falsos negativos costuma ser alto.

9. Análise crítica

A Regressão Logística sem PCA teve maior Precision e menos falsos positivos, mas perdeu mais fraudes do que a versão com PCA. A Regressão Logística com PCA aumentou o Recall e o F1, sendo o melhor modelo final para o objetivo definido.

O Isolation Forest teve desempenho inferior em F1 e Recall. Embora o ROC-AUC tenha sido alto, a classificação final gerou muitos falsos negativos, especialmente com PCA. Isso mostra que um bom ranking de anomalia não garante uma decisão operacional adequada em bases extremamente desbalanceadas.

Modelo	Impacto em Precision	Impacto em Recall	Impacto em F1	Impacto em PR-AUC
Regressão Logística	-0,036	+0,047	+0,011	+0,015
Isolation Forest	-0,256	-0,068	-0,132	-0,072

10. Respostas teóricas

Quando usar cada abordagem?

Usaria Regressão Logística quando há histórico rotulado confiável, necessidade de interpretabilidade e possibilidade de calibrar o threshold conforme o custo de erro. Usaria Isolation Forest quando há poucos rótulos, rótulos incertos ou necessidade de triagem inicial de anomalias.

É possível combinar os dois métodos?

Sim. Uma estratégia OR aumenta Recall, sinalizando fraude quando qualquer modelo suspeita. Uma estratégia AND aumenta Precision, sinalizando apenas quando ambos concordam. Também é possível usar uma cascata, com Isolation Forest como triagem e Regressão Logística como refinamento, ou stacking com os scores dos dois modelos.

Como isso se conecta com outros domínios?

A mesma lógica aparece em cibersegurança, manutenção preditiva, saúde, IoT e controle de qualidade: eventos críticos são raros, rótulos podem ser incompletos e falsos negativos geralmente têm alto custo.

11. Conclusão

O melhor modelo da análise foi a Regressão Logística com PCA. Ela apresentou o maior F1-Score e o maior Recall entre os modelos finais, mantendo baixa quantidade de falsos positivos. O Isolation Forest cumpriu o papel de comparação não supervisionada, mas não superou o modelo supervisionado quando havia rótulos confiáveis disponíveis.